データ分析ポートフォリオ

審査項目別延滞率の分析・与信判断の意思決定支援

（Python・SQL）

使用ツール

- Python

→pandas・matplotlib・numpy・sklearn

グラフ作成・ロジスティック回帰に使用

- SQL

→sqlite3

項目別影響率計算に使用

目的・背景

- 目的

審査項目別の延滞率影響度を分析し、与信判断時の意思決定に役立てる

- 背景

現職での与信判断時、感覚での判断が多いと感じていたため、
どの項目を優先して確認するべきか定量的に把握し、
審査時間短縮に役立てたいと考えたため

データ概要

- 仮想データ作成
  - ・件数　5000件
  - ・項目別作成時のルール

審査項目	範囲	ルール
年齢	20～60歳	完全ランダム
年収	200～1000万円	年齢↑＝年収↑　微量のランダム
勤続年数	0～30年	年齢↑＝勤続年数↑　微量のランダム
延滞回数	0～6回	年齢↓・年収↓・勤続年数↓＝延滞回数↑
延滞金額	他社0～200万円 自社0～50万円	延滞回数↑＝延滞金額↑　微量のランダム
借入金額	他社0～500万円 自社0～100万円	延滞回数↑＝借入金額↑　微量のランダム

分析方法１

- 項目別延滞率計算

・使用ツール　SQL

・コード説明

SELECT

CASE WHEN 審査項目（グループ別）THEN… END ,　20代、30代など審査項目を分ける

AVG(延滞かどうか)　延滞率計算

FROM 仮想データ

GROUP BY審査項目（グループ別）グループごとの延滞率を出す

分析方法２

- 延滞予測モデル作成

・使用ツール　Python

・コード説明

説明変数：審査項目

目的変数：延滞率

モデル生成：model=LogisticRegression(class_weight='balanced' max_iter=1000)

※ class_weight='balanced'

→延滞しない人「多」・延滞する人「少」の不均等があるためウェイト調整

※ max_iter=1000

→デフォルト(100)だとモデルが適切に収束せず最適解を導き出せなかったため1000に設定

（モデルの精度を上げるための学習回数のこと）

閾値：threshold = 0.47 →再現率高めになるよう設定

（延滞する人を延滞しないと判断することを少なくするため）

分析方法３

- モデルの評価
  - 再現率:0.70

    →延滞する人を延滞しないと判断することを少なくするため高め◎
  - 混合行列[[573 238] [56 133]]

    →TP：573（延滞しない人を延滞しないと判断）

    FN：238（延滞しない人を延滞すると判断）

    FP：56（延滞する人を延滞しないと判断）☆ここが少ないと◎

    TN：133（延滞する人を延滞すると判断）
  - AUC:0.78

    →1に近いほど◎

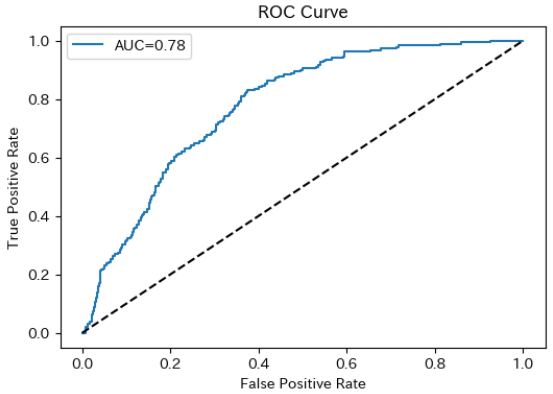

分析方法４

- 延滞率影響度ランキングの作成
  - 使用ツール　Python
  - コード説明

```
df[“影響度”] = df["係数"].abs()
```

→ロジスティック回帰で出した係数を絶対値に変換

```
df = df.sort_values("影響度", ascending=False)
```

→大きい順に並び変え

処理フロー図

データ準備・集計	仮想データ作成（Python）	項目別・属性別で延滞率集計（SQL)
可視化・傾向把握	棒グラフ作成（Python）	延滞率を視覚化してどの項目・属性が目立つか確認
モデル作成・影響度評価	ロジスティック回帰でモデル作成	係数から影響度ランキング作成・優先項目を特定

分析結果１（項目別延滞率グラフ）

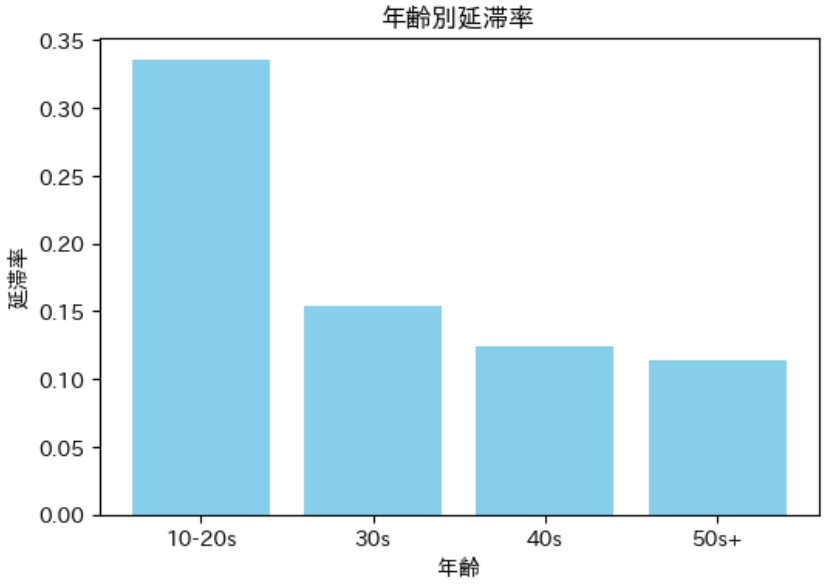

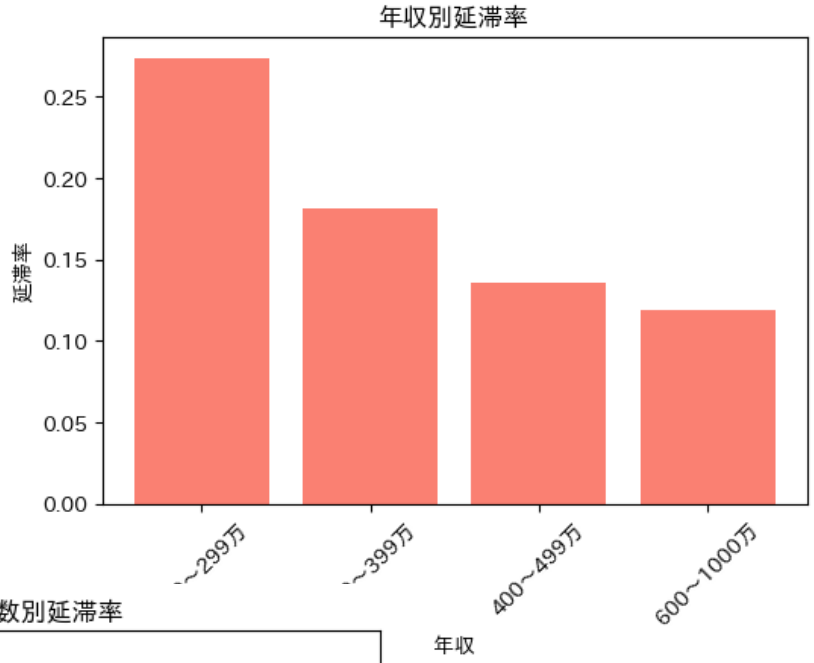

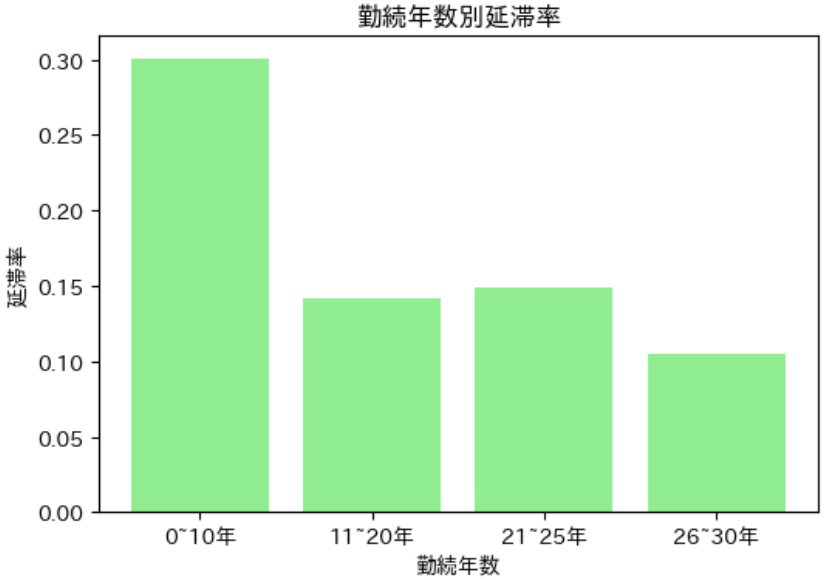

分析結果２（項目別延滞率グラフ）

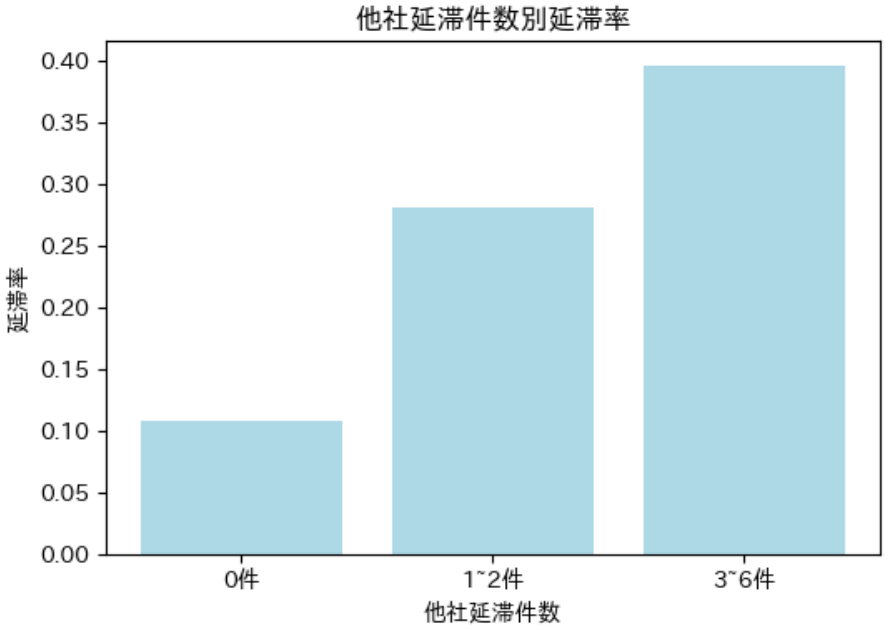

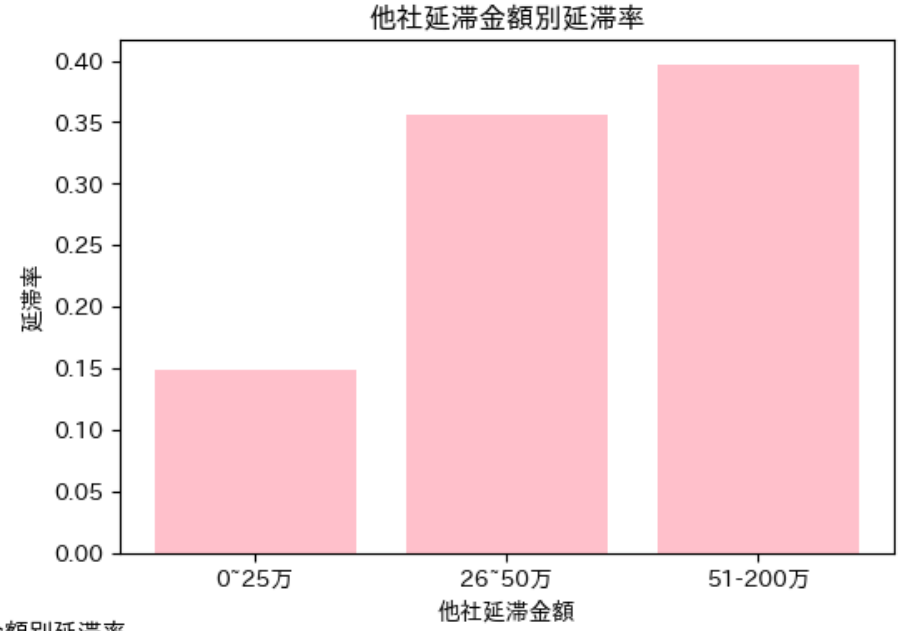

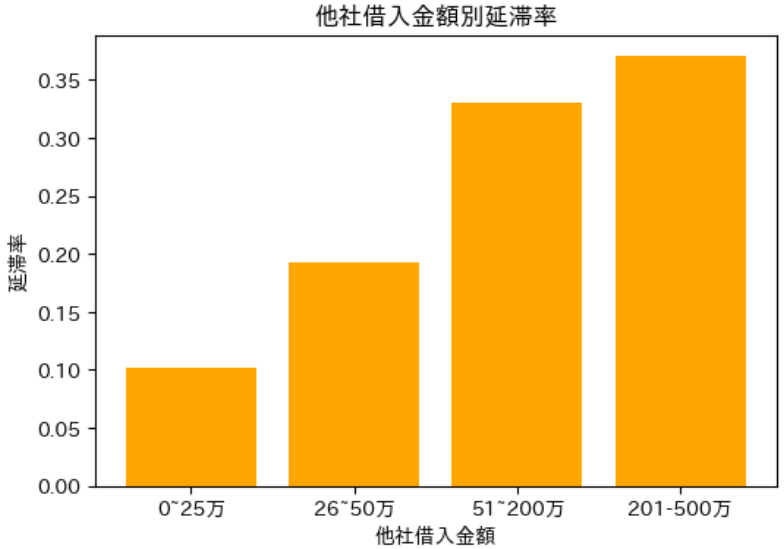

分析結果３（項目別延滞率グラフ）

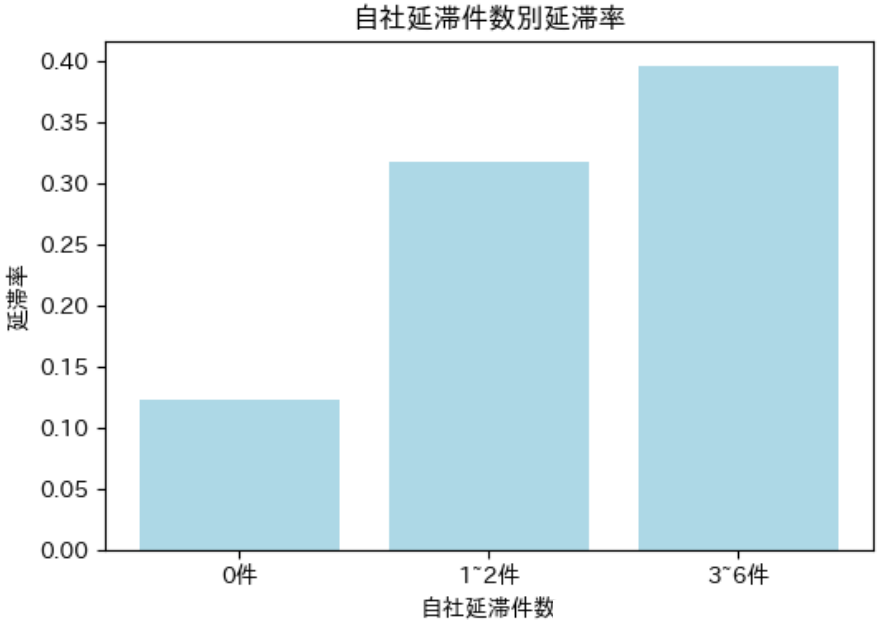

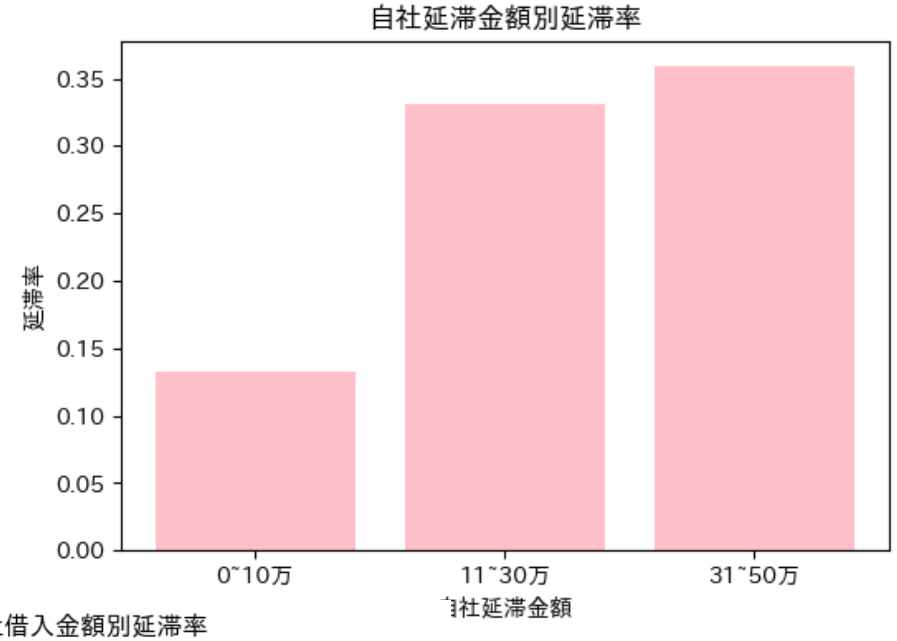

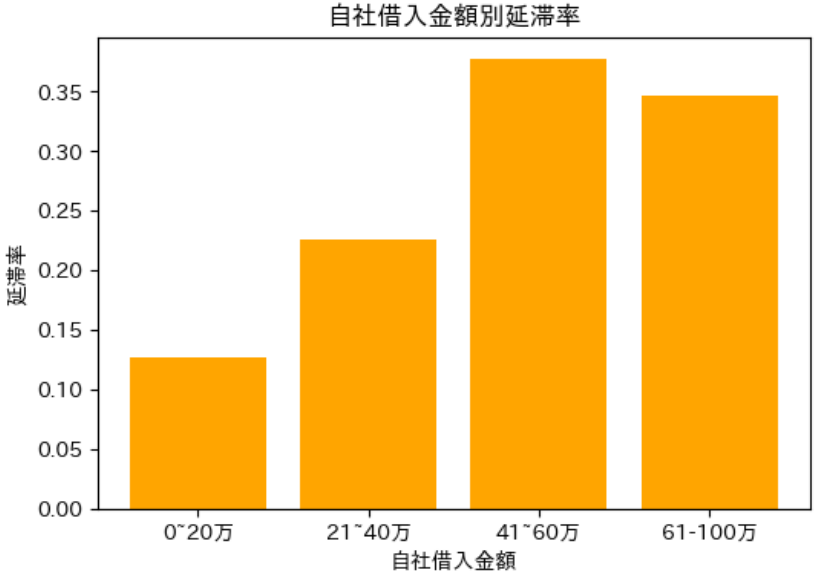

分析結果４（影響度ランキング）

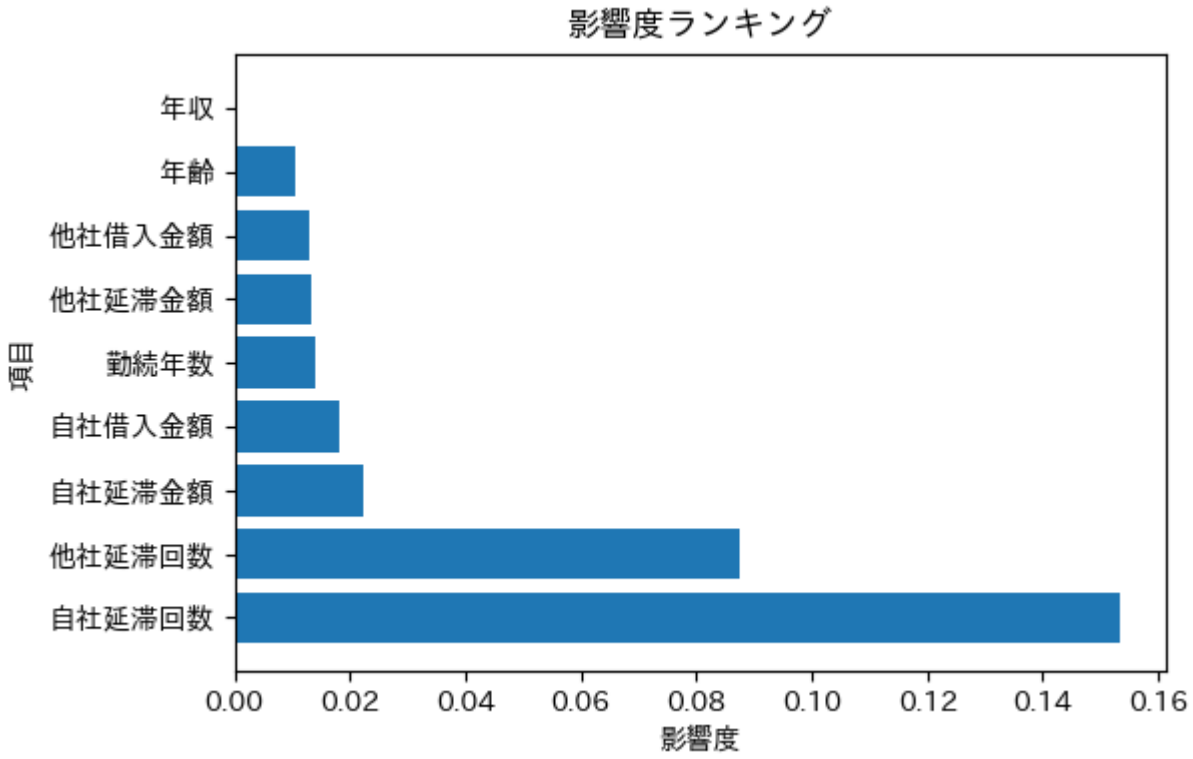

項目	係数	影響度
自社延滞回数	-0.15349	0.153493
他社延滞回数	-0.08761	0.087612
自社延滞金額	0.022217	0.022217
自社借入金額	0.018124	0.018124
勤続年数	-0.01418	0.014182
他社延滞金額	0.013407	0.013407
他社借入金額	0.012864	0.012864
年齢	-0.01073	0.010726
年収	0.000534	0.000534

考察・まとめ

- 考察

項目別延滞率のグラフでは、「年齢・年収・勤続年数」は少ないほど延滞率が高く、
「延滞回数・延滞金額・借入金額」は自社・他社ともに多いほど延滞率が高い傾向が見られました。
また、影響度ランキングでは自社延滞回数が最も大きく、申込者の属性では勤続年数が年齢・年収より影響度が高いことが確認できました。
これらの結果から、審査時に注目すべき項目の目安が見えてきます。

- まとめ

今回は実データではなく、仮想データでの分析となりました。
結果として出ている内容は、事前に設定した仮想データの内容と基本的に一致しており、
精度の高いモデルを作成できたと考えられます。
今回の手法を実データに応用すれば、審査項目ごとの影響度を定量的に把握でき
優先的に確認すべき項目の判断や審査業務の効率化に役立てられる可能性があります。

改善案・今後の目標

- モデル精度向上

AUC=7.8を8～9へ引き上げるため、

クロス分析や審査項目の追加、他機械学習モデルの追加を検討。

- 審査時間×延滞率のバランス分析

今回のデータに項目ごとの処理時間を設定。

審査負荷と延滞率の最適点を特定し、業務効率と与信精度の両立に役立てる。